


01 CLIP: 对比语言-图像预训练

(1) Contrastive pre-training



从自然语言监督中学习视觉表示

Image Encoder: ResNet 或 ViT (Visual Transformer) 图像特征 I_f 。

Text Encoder: Transformer 文本特征 T_f 。

训练目标: 对比损失

- 最大化真实配对的余弦相似度 (N 对)。
- 最小化错误配对的相似度 ($N^2 - N$ 对)。
- 对称交叉熵损失。

01 CLIP 算法核心流程解析

1. 异构特征提取 (Feature Extraction):

图像与文本分别通过各自的编码器转换为原始向量。

2. 统一语义空间映射 (Joint Embedding):

核心：通过线性投影矩阵，将不同维度的图像（768维）与文本（512维）映射到统一的512维联合嵌入空间。

3. 相似度矩阵计算 (Similarity Matrix):

对映射后的特征进行L2归一化，并计算两两之间的余弦相似度，结果得到一个 $n \times n$ 的相似度得分矩阵 (Logits)。

4. 对称对比损失优化 (Symmetric Loss):

同时计算“图像找文本”和“文本找图像”的交叉熵损失，引导模型学习跨模态的匹配关系。

```
# image_encoder - ResNet or Vision Transformer
# text_encoder - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l] - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T) #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t)/2
```

Figure 3. Numpy-like pseudocode for the core of an implementation of CLIP.


01 Zero-Shot 迁移的力量

机制讲解


Zero-Shot 能力: 无需微调即可对未见过的类别进行分类。

1. 创建 Prompts: "A photo of a {dog}", "A photo of a {cat}".
2. 计算图像特征与文本特征之间的相似度。
3. 预测结果: 具有最高相似度分数的标签。

(2) Create dataset classifier from label text



(3) Use for zero-shot prediction




总结: 成功将视觉特征与自然语言语义映射至统一嵌入空间, 实现了强大的 Zero-Shot (零样本) 迁移能力。

挑战: 由于预训练目标侧重于全局对齐, 导致模型在处理局部细节 (如像素级分割) 时存在特征相关性混乱的问题。

01 差距：为什么 CLIP 做不好分割？

语义分割要求像素级的精确对齐，但 CLIP 的预训练目标侧重于**图像级全局语义**。由于任务目标的错位，直接提取 CLIP 内部的注意力特征会导致显著的局部语义混杂与边界溢出。



(a) **CLIP 预测图**：边界极其模糊，存在严重的类间混杂。

(b) **CLIP 注意力图**：权重分布非常弥散，无法聚焦于物体核心。


(c) **原始图像**：包含多只不同姿态和遮挡关系的棕熊。

(d) **DINO 相似度图**：边缘锐利，具备极强的空间一致性。


(图片来源：(2025 ICCV) Harnessing Vision Foundation Models for High-Performance, Training-Free Open Vocabulary Segmentation)

对比发现，CLIP 虽然具备强大的语义分类能力，但其投影层 W_i 丢失了精细的空间结构信息。这种“相关性混乱”现象证明，在无需训练的前提下，必须引入像 DINO 或 SAM 这样具备局部判别力的模型来重构 CLIP 的特征关联。

02 核心发现：类间相关性是性能瓶颈



(a)



(b)

现象发现与关键结论

类内相关性 (Intra-Class): 有效聚合语义，显著提升分割性能 (mIoU)。


类间相关性 (Inter-Class): 引入不同类别间的图像块交互，无论相似度高低，均会导致性能持续下降。

作者强行限制 CLIP 只能在“类内”或者“对象内”进行信息交互。结果发现，性能出现了巨幅提升。当实验逐步引入 1% 到 20% 的“类间相关性”时，无论引入的是最相似还是最不相似的块，性能都无一例外地开始走下坡路。

结论： 类别间相关性是限制 CLIP 分割性能的主要原因，必须明确规范图像块的交互范围，从物理和数值上双重削弱类间干扰。

02 CorrCLIP 概览：重构相关性

(2025 ICCV Oral) CorrCLIP: Reconstructing Patch Correlations in CLIP for Open-Vocabulary Semantic Segmentation



两大支柱

范围重构: 使用 SAM 定义区域 Masks。

数值重构: 使用 DINO 计算连贯的相似度。

附加模块:

特征优化（空间 & 语义分支）。
Map 校正。

CorrCLIP 利用 SAM 提供的物理边界来限制 ‘看哪里’，借用 DINO 的局部连贯性来决定 ‘怎么看’，最后将这两者重构出的精准注意力，注入到 CLIP 的语义空间里，从而把原本模糊、越界的 CLIP 特征，锻造成了边界清晰、语义准确的分割图。

02 第一步：范围重构 —— SAM 引导




核心目标

解决 CLIP 图像块嵌入不连贯导致的类间相关性问题，从物理上限制 Attention 范围，使其“专心”于特定区域。

关键步骤

- SAM 初始化：**利用 SAM 生成类别无关的 Masks，并下采样匹配特征图大小。
- 区域合并：**基于Token嵌入 F_S 计算全局平均池化得到区域特征 F_{region} ，通过聚类算法合并相似掩码得到 $\hat{M}$ 。
- 构建交互矩阵：**
已分割区域 ($\hat{m}_i$)：允许区域内部自由交互。
未分割区域 (m_0)（背景区域）：设定阈值，仅允许高相似度交互。
- 最终机制：**Masked Softmax: 将矩阵 E 作为掩码应用。




合并区域掩码： $f_i = \text{Mean}(m_i \odot F_S)$ $\hat{M} = \text{Cluster}(M, F_{region})$

计算交互矩阵： $E = \sum_{i=1}^z \hat{m}_i \otimes \hat{m}_i + (m_0 \otimes m_0) \odot (S > \text{Mean}(S))$

掩码Softmax： $Attn = \text{Masked Softmax}\left(\frac{S}{\sqrt{d}}, E\right)$

S: 原始 CLIP 特征相似度矩阵。
E: 本步骤构建的交互掩码矩阵。

02 第二步：数值重构 —— DINO 增强



SAM的问题: Masks可能过度分割或包含多个类别。Mask内部, CLIP 特征依然充满噪声。

核心方法

利用 DINO 的 Query (Q_D)和 Key (K_D)构建更连贯的相似度矩阵。

特征组合: 并不是直接使用原始矩阵, 而是将查询和键嵌入相加 ($Q_D + K_D$)以充分利用 DINO 能力。

相似度矩阵构建:
$$S = \frac{F_S F_S^T}{|F_S|^2} = \frac{(Q_D + K_D)(Q_D + K_D)^T}{|Q_D + K_D|^2}$$

注意力图修正:
$$Attn = \text{Masked Softmax}\left(\frac{S}{\tau}, E\right)$$

S: DINO 增强特征的相似度矩阵。

E: 第一步构建的交互掩码矩阵。

τ : 温度系数。 $\tau < 1$ 用于锐化分布, 放大高相似度块的分值, 抑制类间相关性。

02 第三步：特征精炼 —— 双分支增强




$$F_{img} = \underbrace{\text{Proj}(\text{Attn}V_C)}_{\text{Main}} + \alpha * \underbrace{\text{Proj}(\text{Attn}V'_C)}_{\text{Spatial}} + \beta * \underbrace{\text{MCT}}_{\text{Semantic}}$$

Attn：这里特指自注意力机制。

Proj：投影映射，对注意力机制得到的结果进行维度对齐。

MCT (Mask Class Tokens, 掩码类别标记)：聚合了该区域内所有像素的全局统计信息。



1. 空间分支 (Spatial Branch, $\alpha = 1$):

动机：CLIP 深层特征虽然语义丰富，但丢失了空间细节。

机制：引入较低层的特征 V'_C (保留了更丰富的空间信息)，并进行投影映射。
 V_C 是 CLIP 的顶层特征。

2. 语义分支 (Semantic Branch, $\beta = 0.5$):


掩码类别标记 (Mask Class Tokens, MCT): 在 ViT 输入端为每个合并区域 (z) 添加对应的类别标记。

原本 CLIP 的输入是 [CLS] token + 图像 patch tokens。CorrCLIP 在此基础上额外插入了 z 个全新的、可学习的向量，即 MCT。

受限注意力：每个 MCT 仅关注其对应 Mask (**SAM 合并区域**) 内的图像块，捕获区域特定的全局语义。

注入：最终将 MCT 加回到每一个像素 (Patch) 位置上，增强语义对齐。

02 第四步：地图校正 —— 空间一致性



$$\text{pred}[m_i] = \text{Mode}(\text{pred}[m_i]), \quad i > 0$$

m_i (掩码区域): 经过区域合并后的SAM掩码。

$\text{pred}[m_i]$ (区域预测集): 在这个掩码区域 m_i 范围内, 所有像素点原本的预测类别标签集合。

$\text{Mode}(\cdot)$ (众数算子): 寻找集合中出现频率最高的值。

动机: CLIP 的弱监督性质导致其缺乏全监督方法中的空间一致性, 像素级预测容易出现逻辑突变 (例如: 连贯对象内部出现杂乱噪声)。

策略: 利用前序步骤生成的合并区域掩码, 并通过投票强制区域内部类别统一。因为它们本身代表了空间连贯的区域。

03 实验设置与性能概览




Figure 1. Comparison of OVSS performance on eight benchmarks. “CLIP only” refers to the best performance when only using CLIP.

8个评估基准:

Pascal VOC: VOC20 (无背景), VOC21 (含背景)。

Pascal Context: PC59 (59类), PC60 (60类)。

COCO: COCO Stuff (171类, 复杂场景), COCO Object (81类)。

ADE20k (150类)。

Cityscapes (自动驾驶场景)。

对比基线

CLIP-only 方法: MaskCLIP, SCLIP, ClearCLIP, NACLIP 等 (受限于Patch特征的不连贯性)。

Foundation Model 辅助方法: LaVG, FreeDA, CASS 等 (引入额外模型但缺乏相关性范围限制)。

主要表现

蓝色实线 (CorrCLIP) 包裹了橙色实线 (Previous SOTA), 说明CorrCLIP在所有测试中均取得最佳性能。

在困难数据集 ADE20k 和 COCO Stuff 上提升显著。

03 定量对比结果

Method	Size	VOC21	VOC20	PC60	PC59	Object	Stuff	ADE	City	Avg
Training-based										
TCL[7]	ViT-B/16	55.0	83.2	30.4	33.9	31.6	22.4	17.1	24.0	37.2
CLIP-DINOiser[54]		62.1	80.9	32.4	35.9	34.8	24.6	20.0	31.7	40.3
CoDe[53]		57.7	-	30.5	-	32.3	23.9	17.7	28.9	-
CAT-Seg[10]		77.3	94.6	-	57.5	-	-	31.8	-	-
ESC-Net[29]		80.1	97.3	-	59.0	-	-	35.6	-	-
Training-free										
CLIP[41]	ViT-B/16	11.5	41.9	4.4	9.2	1.6	4.4	2.9	5.0	10.1
MaskCLIP[72]		38.8	74.9	23.6	26.4	20.6	16.4	9.8	12.6	27.9
ClearCLIP[27]		51.8	80.9	32.6	35.9	33.0	23.9	16.7	30.0	38.1
SCLIP[51]		59.1	80.4	30.4	34.2	30.5	22.4	16.1	32.2	38.2
ProxyCLIP[28]		61.3	80.3	35.3	39.1	37.5	26.5	20.2	38.1	42.3
LaVG[23]		62.1	82.5	31.6	34.7	34.2	23.2	15.8	26.2	38.8
CLIPtrasc[44]		53.0	81.2	30.8	34.9	44.8	24.1	17.0	-	-
NACLIP[19]		64.1	83.0	35.0	38.4	36.2	25.7	19.1	38.3	42.5
Trident[45]		67.1	84.5	38.6	42.2	41.1	28.3	21.9	42.9	45.8
ResCLIP[62]		61.1	86.0	33.5	36.8	35.0	24.7	18.0	35.9	41.4
SC-CLIP[1]		64.6	84.3	36.8	40.1	37.7	26.6	20.1	41.0	43.9
CLIPer[48]		65.9	85.2	37.6	41.7	39.0	27.5	21.4	-	-
CASS[25]		65.8	87.8	36.7	40.2	37.8	26.7	20.4	39.4	44.4
CorrCLIP (Ours)		74.8 (+7.7)	88.8 (+1.0)	44.2 (+5.6)	48.8 (+6.6)	43.7 (-1.1)	31.6 (+3.3)	26.9 (+5.0)	49.4 (+6.5)	51.0 (+5.2)
FreeDA[2]	ViT-L/14	55.4	87.9	38.3	43.5	37.4	28.8	23.2	36.7	43.9
CaR[49]		67.6	91.4	30.5	39.5	36.6	-	17.7	-	-
ProxyCLIP[28]		60.6	83.2	34.5	37.7	39.2	25.6	22.6	40.1	43.0
ResCLIP[62]		54.1	85.5	30.9	34.5	32.5	23.4	18.2	33.7	39.1
SC-CLIP[1]		65.0	88.3	36.9	40.6	40.5	26.9	21.7	41.3	45.2
CLIPer[48]		69.8	90.0	38.0	43.6	43.3	28.7	24.4	-	-
CorrCLIP (Ours)		76.7 (+6.9)	91.5 (+0.1)	44.9 (+6.6)	50.8 (+7.2)	49.4 (+6.1)	34.0 (+5.2)	30.7 (+6.3)	51.1 (+9.8)	53.6 (+8.4)
ProxyCLIP[28]	ViT-H/14	65.0	83.3	35.4	39.6	38.6	26.8	24.2	42.0	44.4
Trident[45]		70.8	88.7	40.1	44.3	42.2	28.6	26.7	47.6	48.6
CorrCLIP (Ours)		76.4 (+5.6)	91.8 (+3.1)	42.5 (+2.4)	47.9 (+3.6)	48.4 (+6.2)	32.7 (+4.1)	28.8 (+2.1)	49.9 (+2.3)	52.3 (+3.7)

Table 1. Comparison with state-of-the-art OVSS methods on eight benchmarks in three different sizes of CLIP. Bold fonts indicate the optimal methods and underlined fonts indicate the suboptimal methods. “Avg” represents the averaged mIoU across eight benchmarks.

全面领先

在 ViT-B, ViT-L, ViT-H 三种不同尺寸的 CLIP Backbone 上均取得最优结果，超越所有 Training-free SOTA 方法。

显著的性能提升

Avg mIoU (ViT-L/14): 达到 53.6%，相比次优方法提升 **+8.4%**。

Avg mIoU (ViT-B/16): 达到 51.0%，提升 **+5.2%**。

复杂场景表现更好

在 Cityscapes (自动驾驶场景) 上提升惊人: **+9.8%** (ViT-L)。

在 COCO Stuff (复杂背景) 上提升显著: **+5.2%** (ViT-L)。

03 可视化对比



1. 语义识别准确:

由于明确限制了交互范围，纠正了其他方法常见的分类错误。

2. 对象连续性强:

物体分割完整，内部不再支离破碎。

3. 显著降低噪声:

消除了背景中的杂乱像素，分割图更加纯净，高度接近 Ground Truth。




Figure 4. Qualitative comparison between our method CorrCLIP and the other four methods. “GT” denotes ground truth.

03 消融实验

	SR	VR	MC	FR	VOC21	PC60	Object	ADE	City
Baseline (CorrCLIP)					53.6	31.9	32.0	19.3	30.5
	✓				68.1	39.6	41.5	24.0	42.0
	✓	✓			68.5	40.3	42.0	24.0	43.2
	✓	✓	✓		72.5	42.0	43.7	25.3	48.3
CorrCLIP	✓	✓	✓	✓	74.8	44.2	43.7	26.9	49.4

Table 2. Impact of integrating different components.

1. 核心突破：范围重构

现象：仅引入 SR，VOC21 性能即从 53.6% 跃升至 68.1% (+14.5%)。

结论：证明了 "不受控的类间相关性" 是限制 CLIP 性能的最大瓶颈。

SR 是这一方法的基石。

2. 空间一致性：图校正 (MC)

现象：在 Cityscapes 上带来显著提升 (+5.1%)。

结论：通过强制区域内部的一致性，有效解决了复杂场景下的碎片化问题。

3. 细节优化：VR & FR

VR (数值重构)：利用 DINO 优化相似度数值。

FR (特征精炼)：进一步提升特征的判别力。


整体：四个组件协同工作，共同达成 SOTA。

03 代码复现与结果展示



CorrCLIP Segmentation

Upload an image, provide class names, choose a mask generator, and adjust parameters.



Class Names (comma-separated)

e.g., 'cat,dog,background'

pikachu,eevee,background

Mask Generator



EntitySeg



SAM2

Detected Classes

pikachu; eevee; background

03 代码复现与结果展示



CorrCLIP Segmentation

Upload an image, provide class names, choose a mask generator, and adjust parameters.



Class Names (comma-separated)


e.g., 'cat,dog,background'

background, banana, pineapple, broccoli, potato, tomato, chili pepper, kiwi, avocado, orange, lemon, strawberry, cherry tomato, parsley, lime

Mask Generator

☒ EntitySeg

☐ SAM2



Detected Classes

background; banana; pineapple; broccoli; potato; tomato;
chili pepper; kiwi; avocado; orange; lemon; strawberry;
cherry tomato; parsley; lime

问题

1. CLIP 的全局预训练目标导致其注意力机制存在“相关性混乱”。
2. 不受控的“类间相关性”是限制其在语义分割任务表现的主要瓶颈。

方法

1. **范围重构**: 引入 SAM 提供的物理掩码, 强制限制 Attention 的交互范围, 消除背景干扰。
2. **数值重构**: 利用 DINO 的局部特征平滑性, 修正相似度矩阵, 增强空间连贯性。
3. **多维增强**: 结合空间/语义双分支特征精炼与 Map 投票校正。

主要贡献

1. **性能卓著**: 在无需任何训练的情况下, 在 VOC、COCO、ADE20k 等8个基准上取得 SOTA。
2. **范式创新**: 证明了通过协同不同特性的视觉基础模型 (SAM 的边界 + DINO 的局部性 + CLIP 的语义), 可以有效解决单一模型的局限。